

ISP TW

Jason Lin

2024/11/15

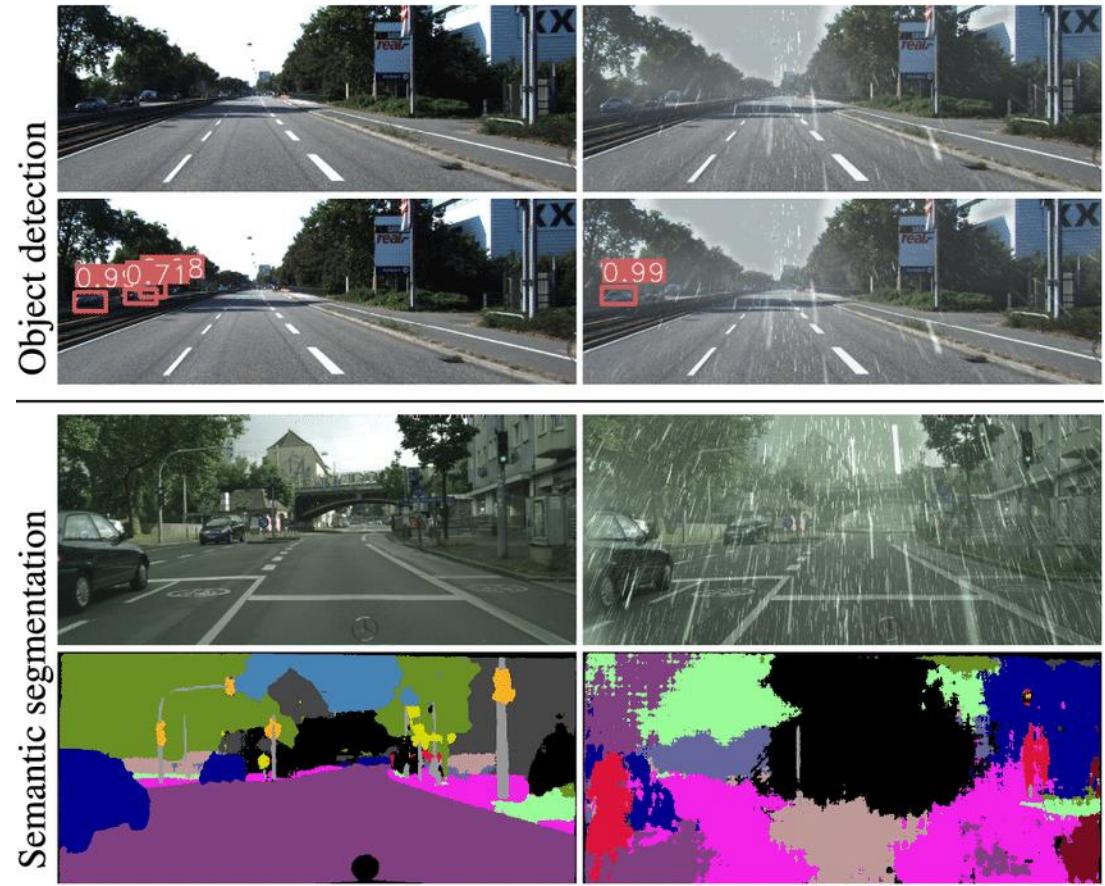
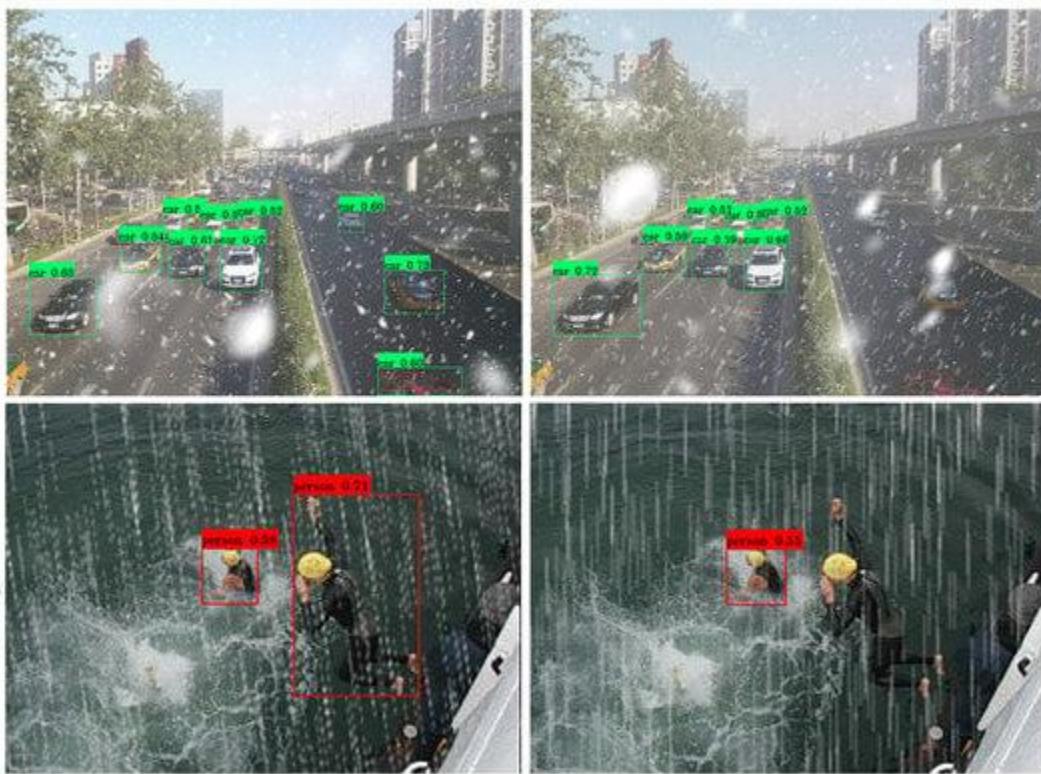
大纲

- 去雨滴
- 低光照增强
- 噪声抑制

去雨滴 -- 前言

- 户外视觉系统（例如，静止图像或动态视频序列）捕捉到的降雨模式或条纹通常会导致图像或视频中出现尖锐的强度波动，导致视觉感知系统在不同任务中的性能下降，例如
 - 行人检测
 - 物体跟踪
 - 语义分割
- 尝试处理被雨水破坏的图像/视频数据并去除雨水条纹，其目的是为下游视觉任务实现良好的图像质量
- 在许多关键的实时应用中，能够在芯片上有效地执行去雨滴是非常重要的。在保持低开销的同时，实现高效和高性能的去雨滴算法对于实际应用非常重要

去雨滴 -- 前言

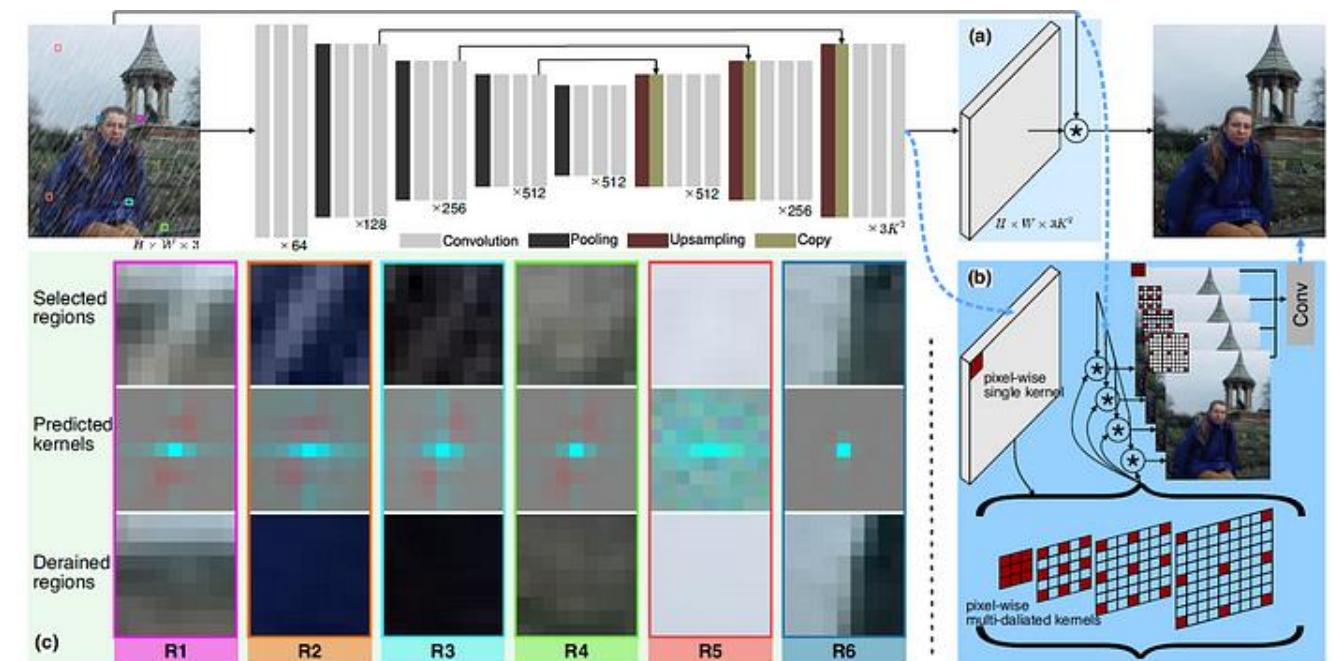


去雨滴 -- 介绍

- 本论文使用不同的角度来处理单个图像的去噪问题，并提出一种有效而通用的去噪方法。
 - 本方法是无模型的，它不假设降雨是如何产生的
 - 论文提出的方法遵循单阶段，不需要迭代优化或渐进式重新定义，从而导致高效率下降
- 论文的主要贡献有三方面
 - 提出了像素扩展滤波，以实现有效的去噪
 - 提出了RainMix组件，用于简单而有效的数据增强，这使我们能够训练网络来处理真实的降雨图像
 - 能够在平均约6ms内处理降雨图像，比最先进的方法（即RCDNet）快80多倍，同时实现类似的去噪效果

去雨滴 -- 方法

- 雨可视为跟遮蔽、雾、动态模糊一样对影像质量造成损害，类似噪声。在图像处理中针对噪声我们常使用 filtering 方式处理，因此使用多样的 kernel 对雨图做 filtering 来处理多样化的雨是很合理的方式



去雨滴 -- 方法

- 公式1

- I_{head} 为除雨后的图，是由多个kernel和雨图做pixel-wise convolution的结果

$$\hat{I} = \mathbf{K} \odot I^r, \quad (1)$$

- 公式2

- 深入针对每个pixel p ，我们除雨的每个pixel的结果会是由原本的雨图的pixel与他所相对应的kernel做convolution的结果

$$\hat{I}(p) = \sum_{t,q=p+t} \mathbf{K}_p(t) I^r(q), \quad (2)$$

去雨滴 -- 方法

- 可以看到基本架构跟U-Net很像，U-Net的好处是在抓细微的特征上非常有效并且训练的数据量不用非常大量即可以有不错的效果，在速度上也非常有利
- 首先我们先输入一张雨图，接着进入到同样宽高的convolution layer 并经过avg pooling后下降一层依此类推
- 一直到Up-sampling后我们会将前面的feature map，透过concat把维度加起来依此类推，最后可以得到雨的feature map
- 我们将此张feature map当作dilated convolution kernel里面权重的参考 与原本的雨图个别进行convolution得到4张dilated convolution的结果图
- 将这4张图进行3*3的convolution取得最终除雨的结果

去雨滴 -- 结果



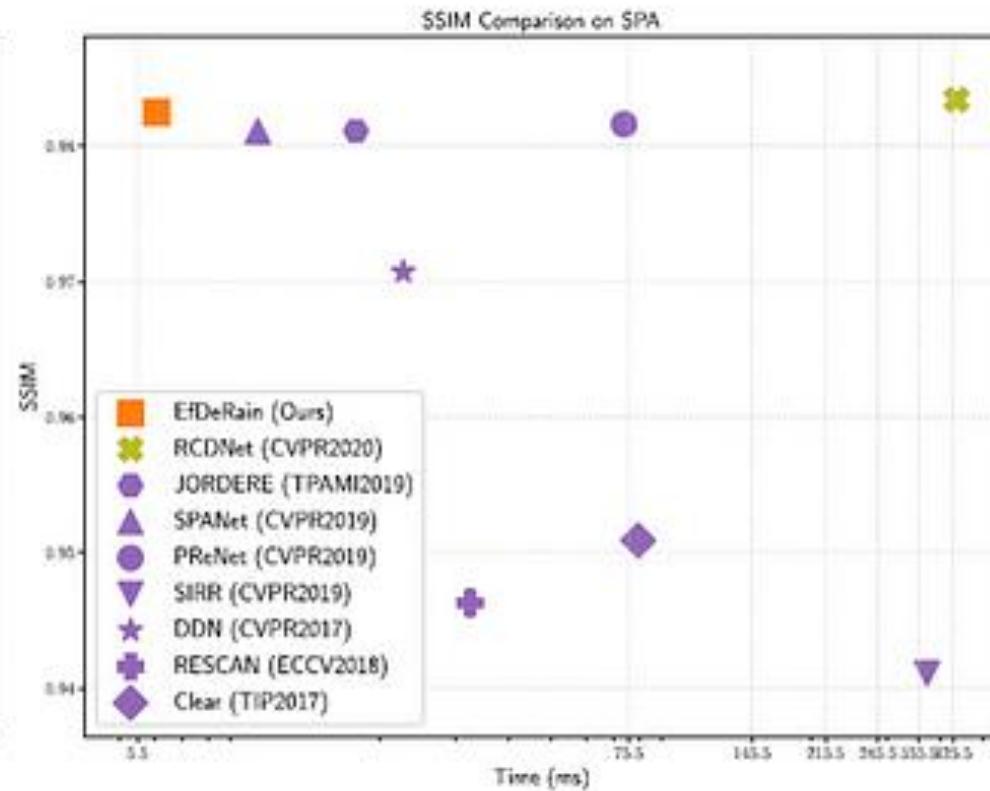
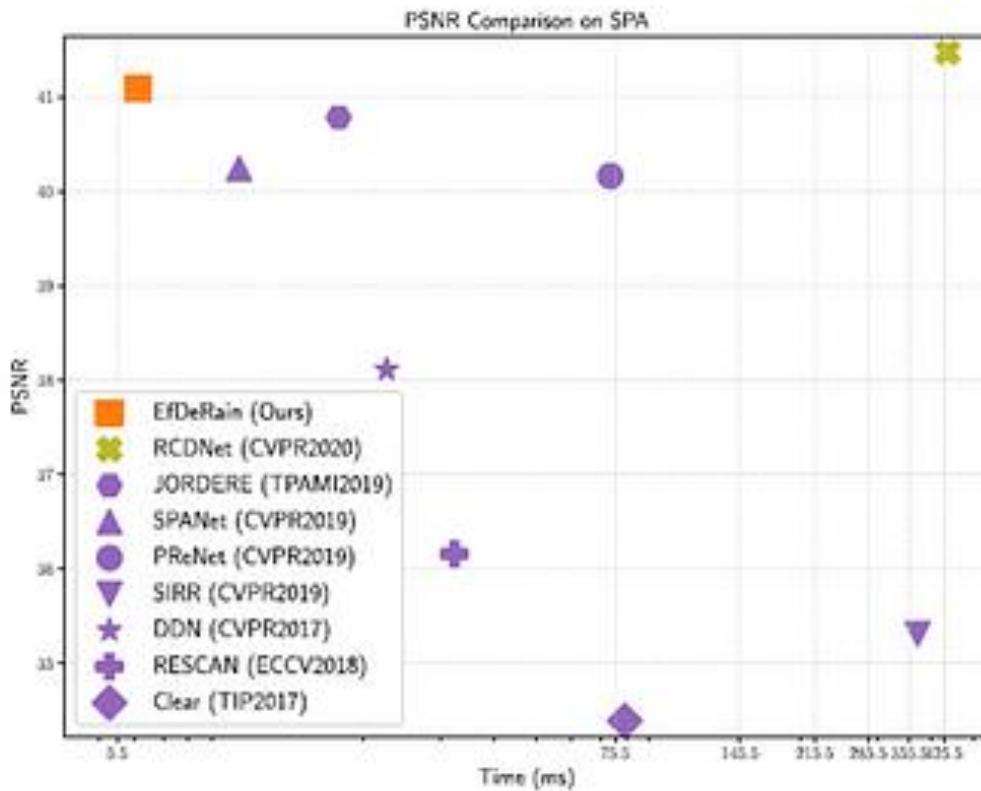
Real Rainy Image



EfDeRain (Ours)

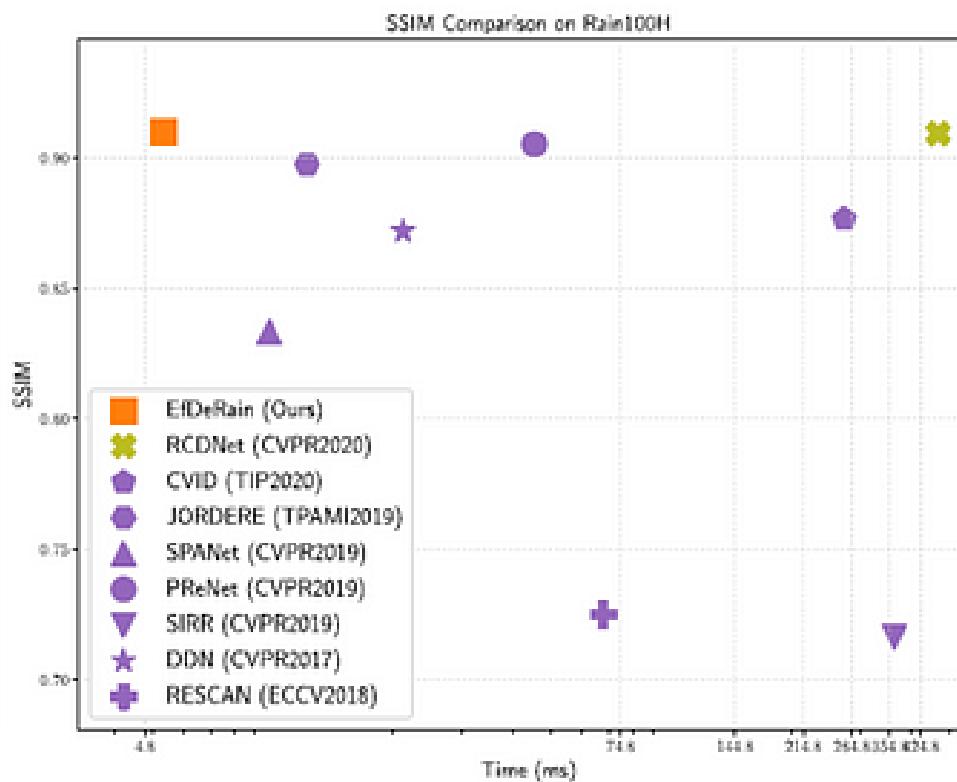
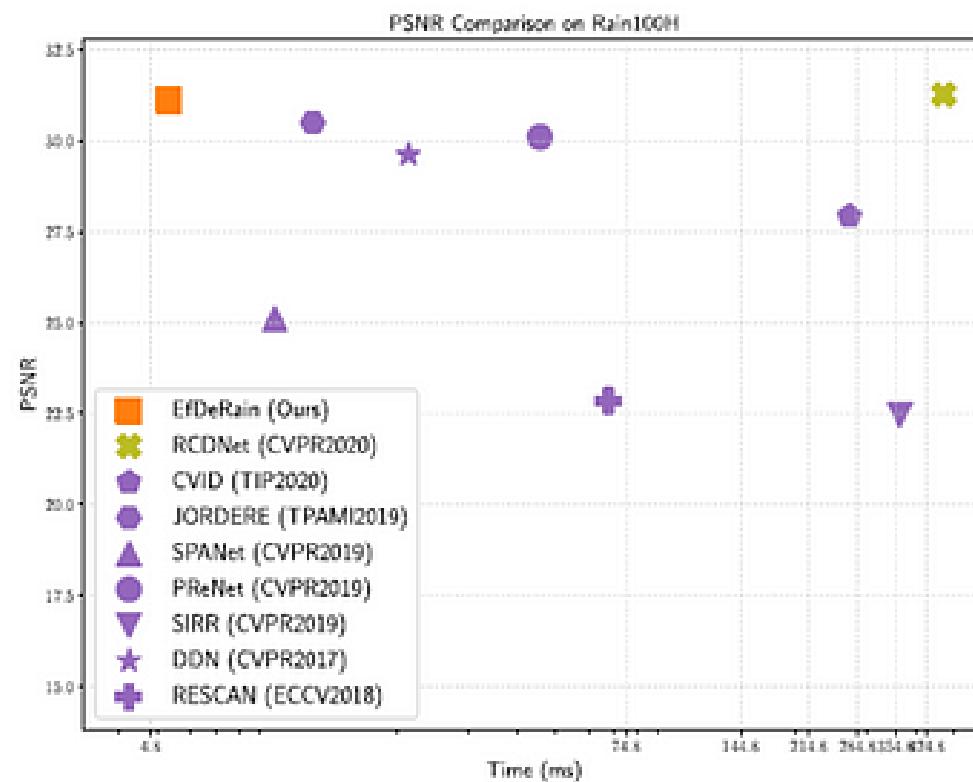
去雨滴 -- 结果

- Comparison on Real-world SPA Rain Dataset



去雨滴 -- 结果

- Comparison on Rain100H Dataset



低光照增强 -- 前言

- 在现实世界中，由于不可避免的环境或技术限制(如照明不足和曝光时间有限)，低光照成像相当普遍。
- 低光照成像不仅对人类感知具有较差的可视性，而且不适合后续的下游计算机视觉任务。
- 因此，我们提出了低光照成像增强(LLIE)来揭示低光照图像中隐藏的细节，并避免在后续视觉任务中降低性能
- 最近，许多基于深度学习的LLIE方法被提出，deep LLIE方法得益于其对低光照和高质量图像之间映射的建模能力，通常比传统方法获得更好的结果。然而，现有的方法通常对微光图像进行全局统一的改进，而没有考虑不同区域的语义信息，而语义信息是增强的关键。如图1(a)所示，缺乏语义先验利用的网络很容易偏离区域的原始色调

低光照增强 -- 前言



(a) Visual comparison on various scenes including car, human and sky.

低光照增强 -- 前言

- 提出了一个语义感知的知识引导框架 (SKF)，通过保持颜色一致性并提高图像质量来提高现有方法的性能。
- 提出了三个关键技术来利用语义知识库 (SKB) 提供的语义先验：语义感知嵌入 (SE) 模块、语义引导颜色直方图 (SCH) 损失和语义引导对抗 (SA) 损失

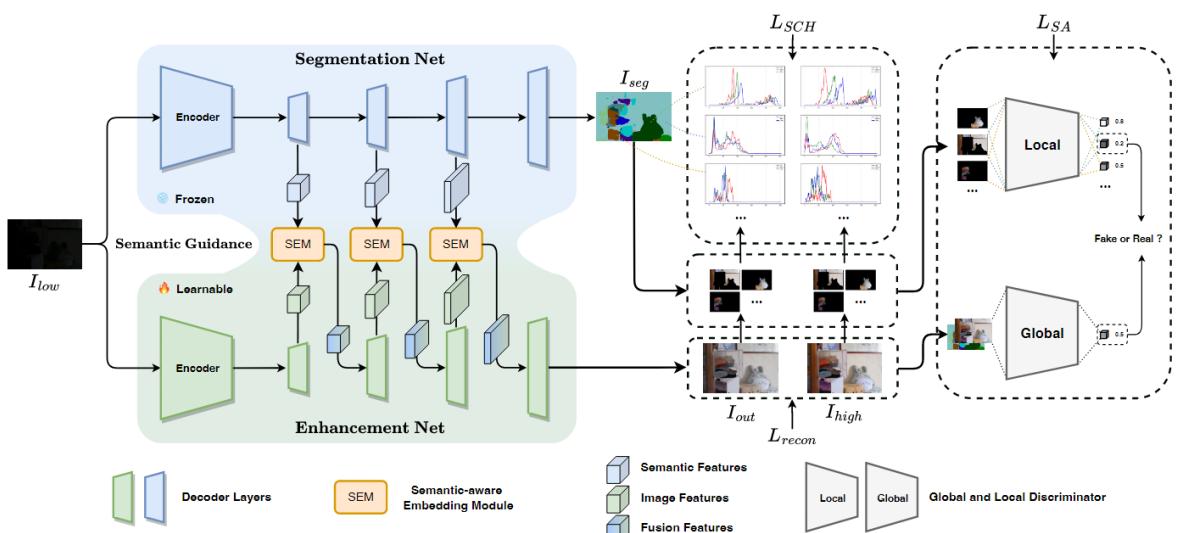


Figure 2. Overview of our Semantic-aware Knowledge-guided Framework (SKF). With a pre-trained Segmentation Net, our SKF utilizes semantic priors to improve the enhancement process in two aspects: (a) In feature-level, the multi-scale semantic-aware embedding modules enable cross-modal interactions between semantic features and image features in representation space. (b) In loss-level, the semantic segmentation result is introduced into the computation of color histogram loss and adversarial loss as a guidance.

低光照增强 -- 方法

• 语义感知嵌入模块 Semantic-Aware Embedding Module

- 在利用语义先验细化图像特征时，需要特别考虑的另一个挑战是两种来源之间的差异。
- SE模块(semantic-aware embedding)就像分割网和增强网之间的桥梁(见图2)，在两个异构任务之间建立连接。

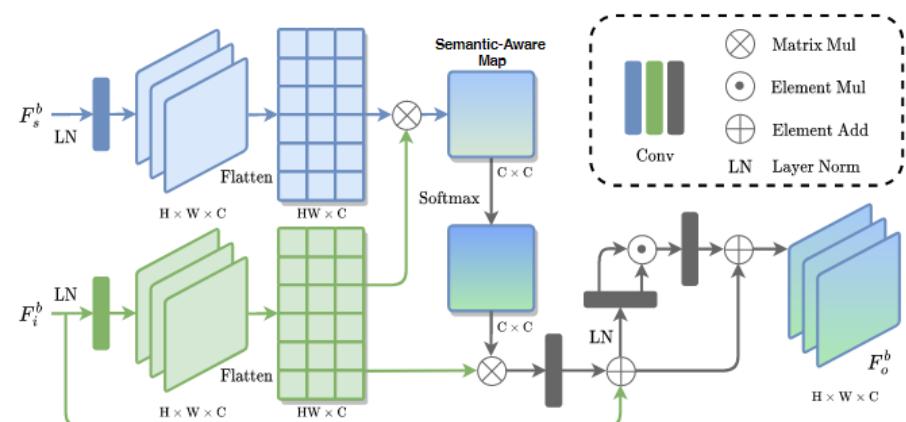
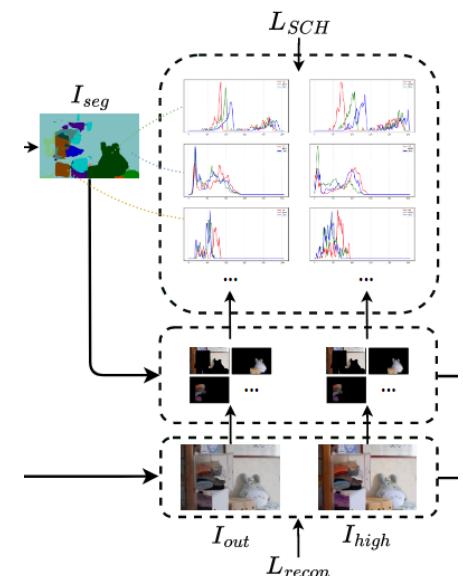


Figure 3. Architecture of the semantic-aware embedding (SE) module. At the b^{th} decoder layer, SE module transforms the image feature map F_i^b with the semantic feature map F_s^b and produces the refined output feature F_o^b .

低光照增强 -- 方法

- 语义引导的颜色直方图损失(Semantic-Guided Color Histogram Loss)

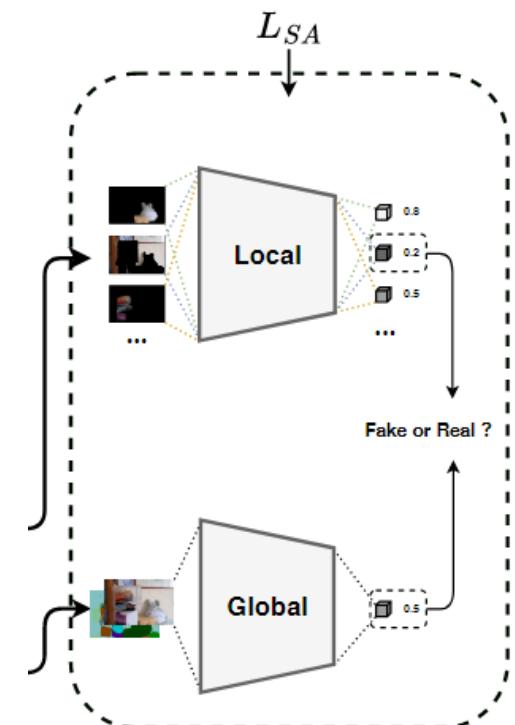
- 颜色直方图携带关键的底层图像统计信息，有利于学习颜色表示，但颜色直方图描述的是全局统计信息，消除了不同实例之间颜色特征的差异
- 因此本文提出了语义引导的颜色直方图(SCH)损失来实现局部颜色调整，保留更详细的颜色信息



低光照增强 -- 方法

- 语义引导的对抗损失 Semantic-Guided Adversarial Loss
 - 此处引入语义信息来指导判别器专注于有价值的区域，使用语义分割图和图像分别进一步细化全局和局部对抗损失函数，提出了语义引导的对抗(SA)损失
 - 最终本文提出的SKF的整体损失函数定义为

$$\mathcal{L}_{all} = \mathcal{L}_{recon} + \lambda_{SCH} \mathcal{L}_{SCH} + \lambda_{SA} \mathcal{L}_{SA}$$



低光照增强 -- 结果

输入



输出



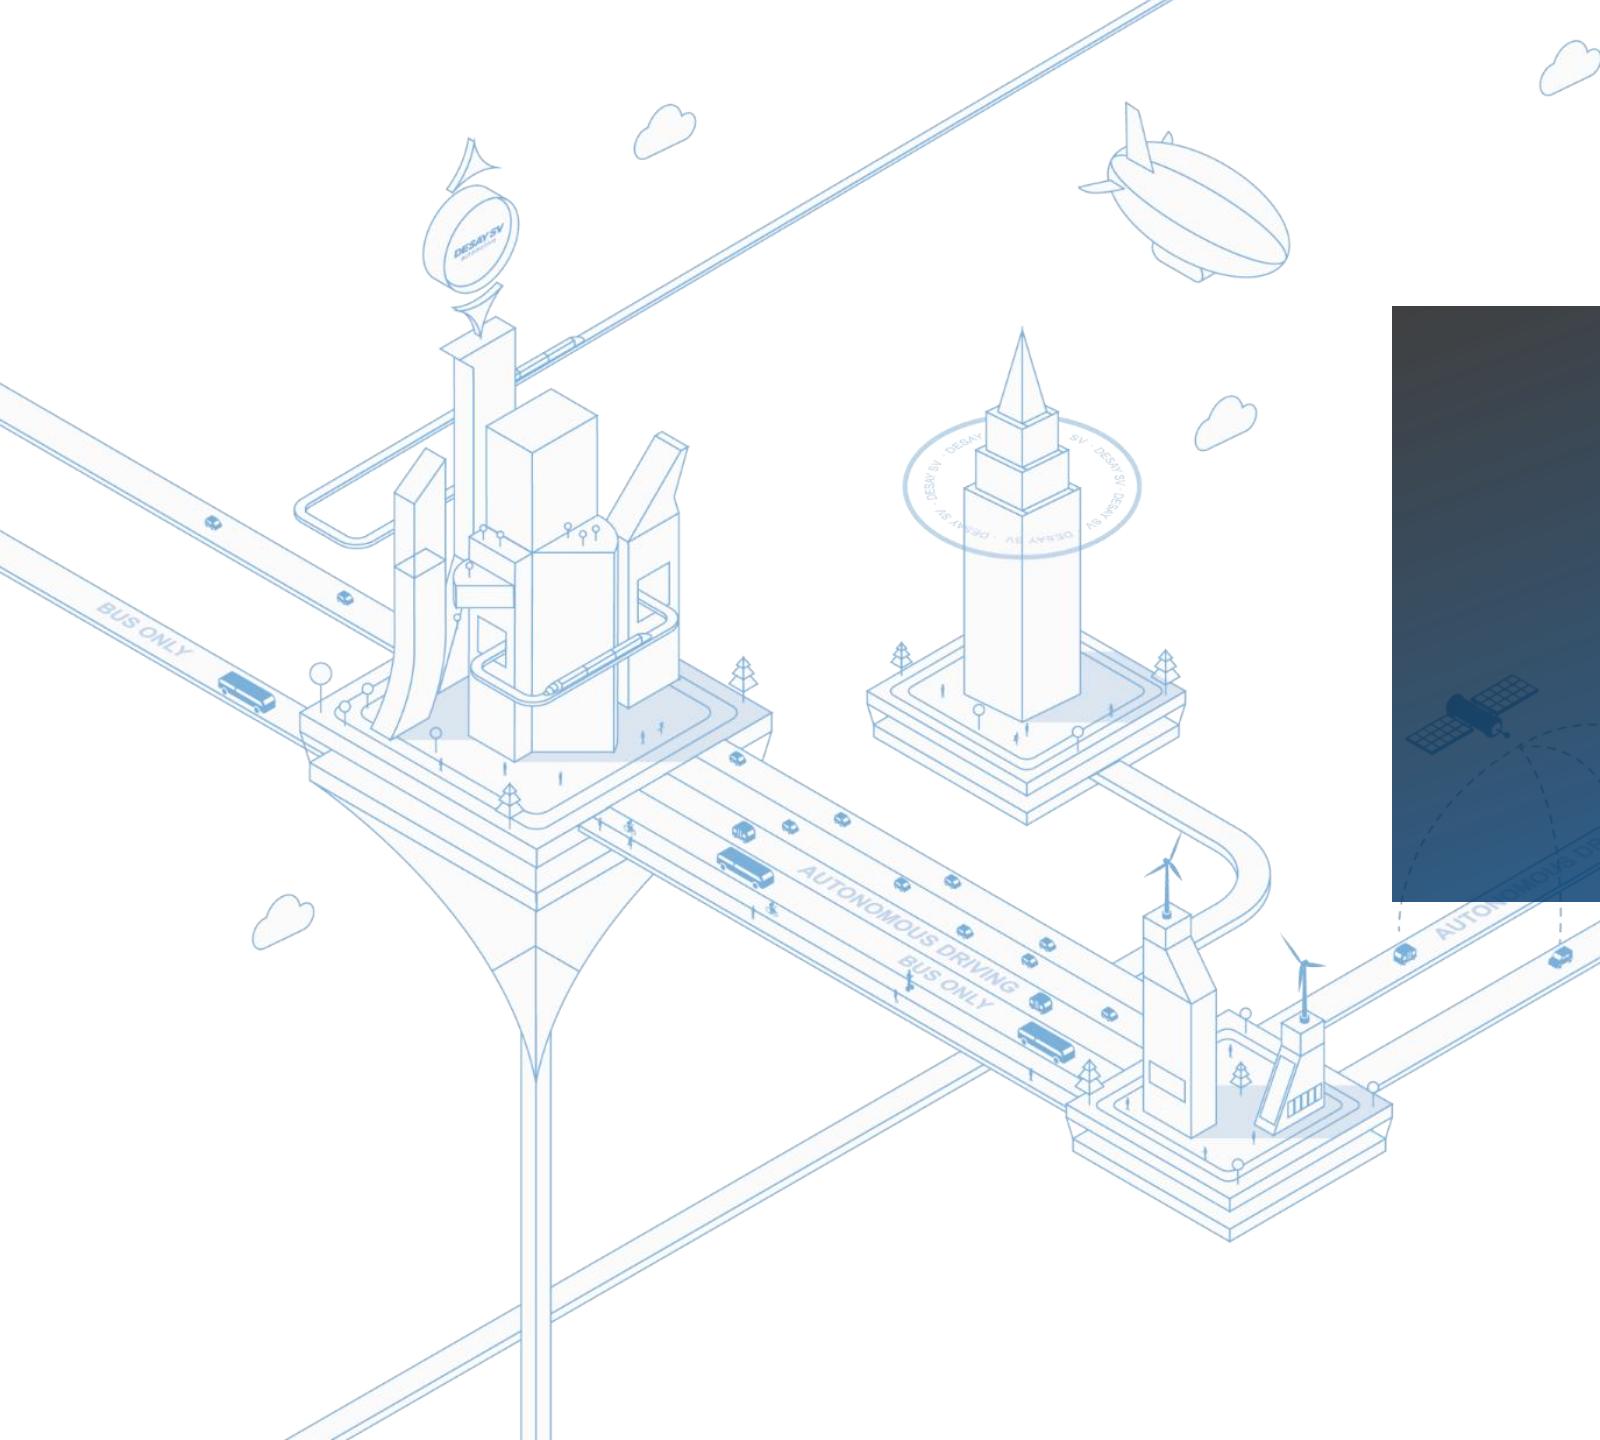
低光照增强 -- 结果

输入



输出





大纲

- 噪音场景描述
- 方法 -- FastDVDnet
- 论文实作结果(5FPS 512*512)
- 实验室色卡校正结果(5FPS 1920*1280)
- 输入影片拆分成训练、测试集(30FPS 1920*1280)

场景描述

输入影片

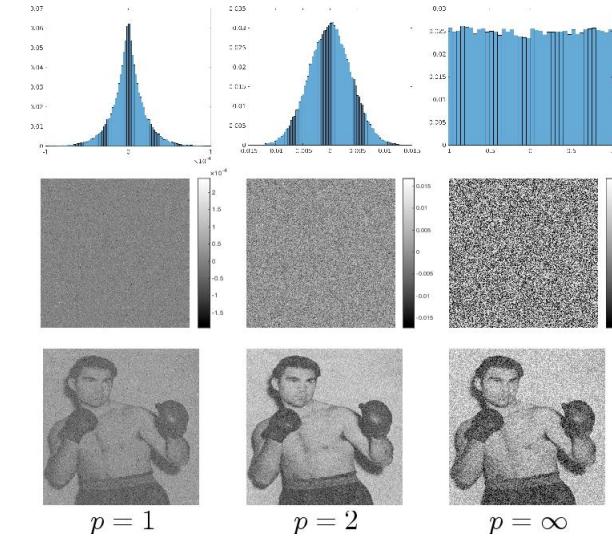


(a) Noisy
Frame 9 (b) Noisy
Frame 10 (c) Noisy
Frame 11 (d) Denoised
Frame 10

利用影片前后帧数作为图像处理的标准
(可选择3、5、7 等 frames)

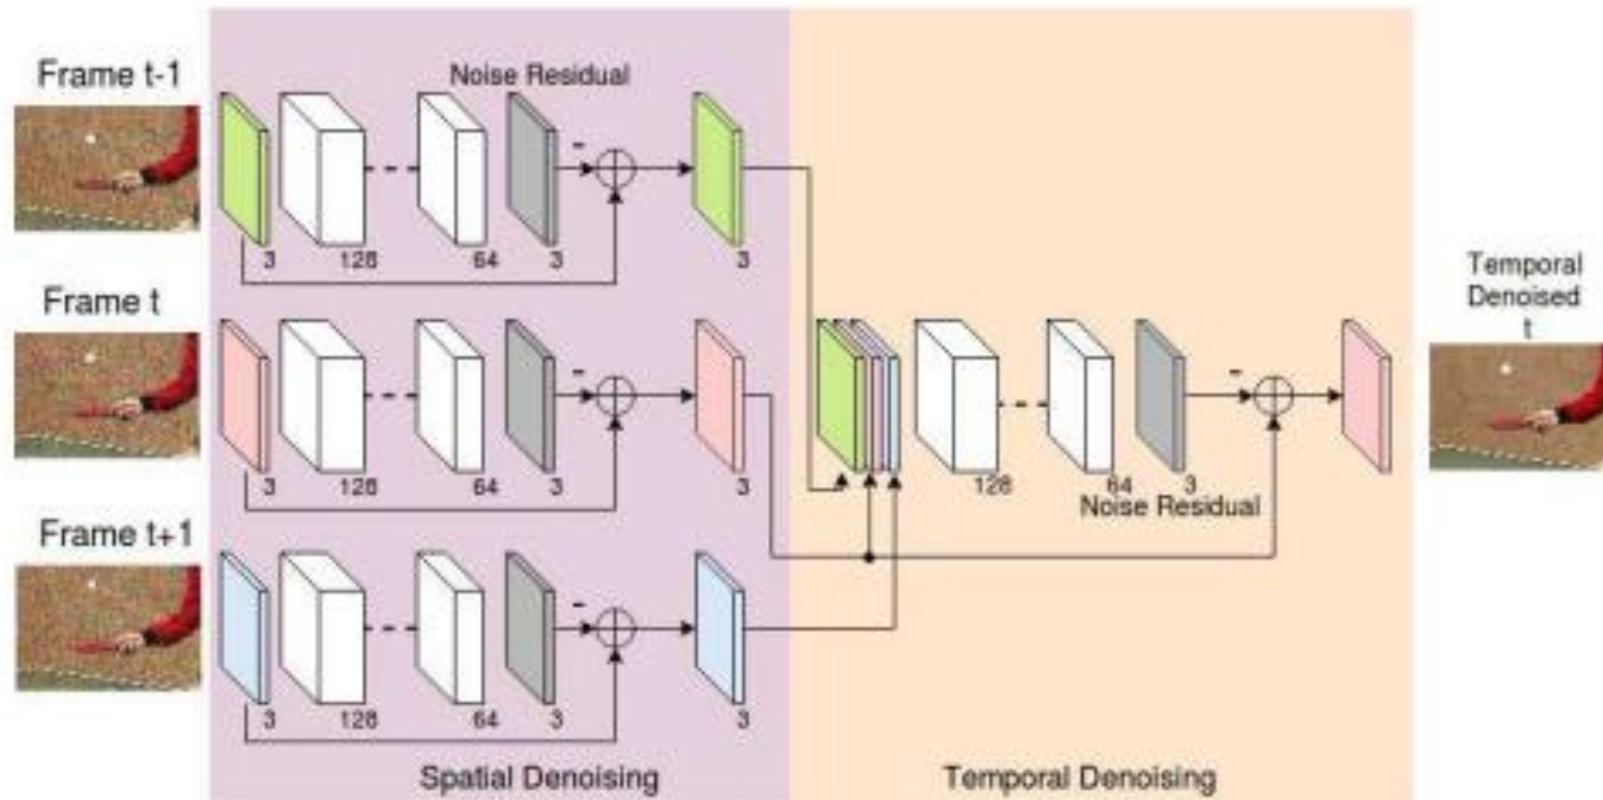


(a) Low-light Noisy
Image (b) Reference Ground
Truth



不只利用人工添加噪音，在较暗的情景撷取到的影像，就有自然的噪音(论文取名叫暗光微粒)

方法 -- FastDVDnet



$$L = \sum_x \sum_y \underbrace{\left(Y(x, y) - Y_{est}(x, y) \right)^2}_{\text{Noise Residual}}$$

Loss Function

论文实作结果(5FPS 512*512)



Noisy

Denoised

Original

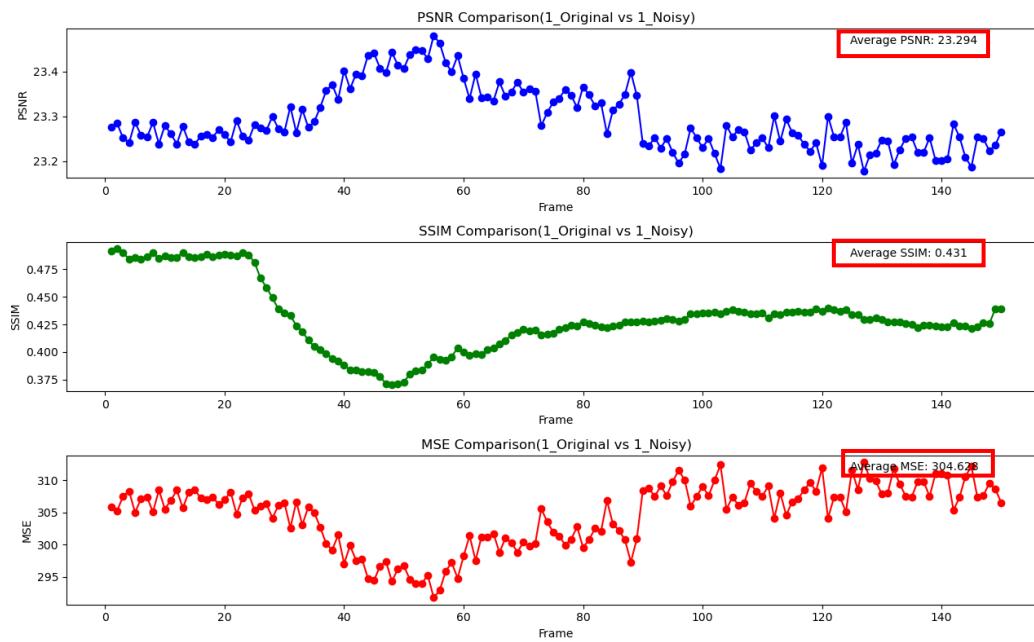
*这边将training、validation的结果(.pt档)套回有noise的影片再做一次denoise，因为其在训练时，帧数的顺序已被拆散

客观指标判读

Original : Clean Video

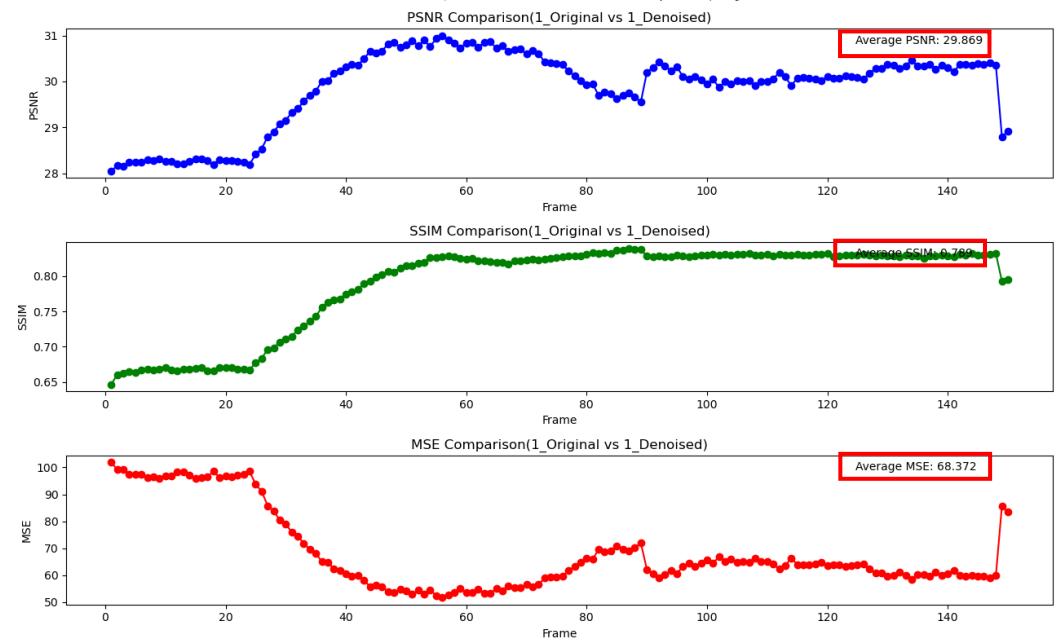
Noisy : Noisy Video

Denoised : Denoised Video



Before

可以看出原本有noise的影片经过降噪模型训练后，可以得到相对好的PSNR、SSIM，并且MSE下降许多。



After

色卡去噪结果

用肉眼可明显看出Denoise后颗粒感消失，但背景相较Target较没那么平滑。

5FPS共10帧



Noisy



Denoised

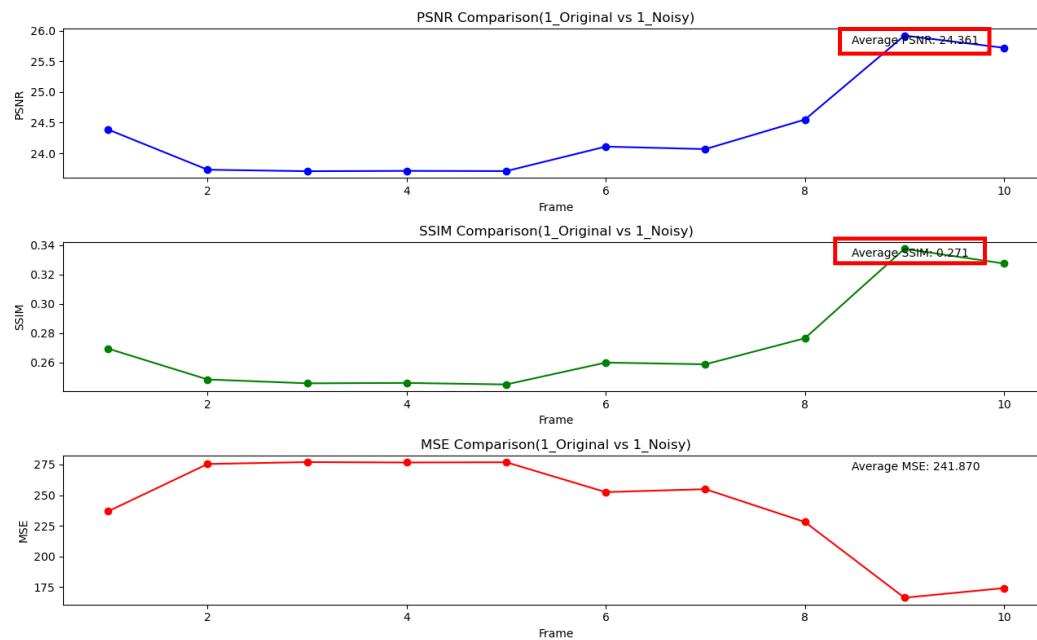


Original

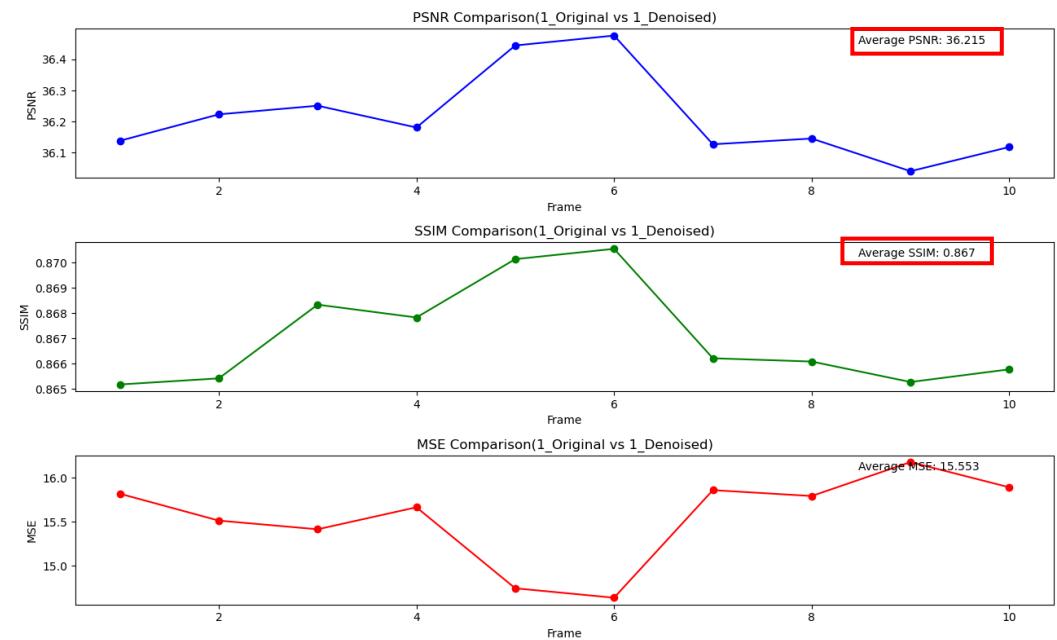
*这边将training、validation的结果(.pt档)套回有noise的影片再做一次denoise，因为其在训练时，帧数的顺序已被拆散

客观指标判读

客观指标如PSNR、SSIM皆有显著上升(以%作为结果)，显示降噪结果理想



Before Training(Clear vs Noisy)



After Training(Clear vs Denoised)

原始影片SNR(Imatest)

S/N (signal/noise) and SNR(dB) ($20 \cdot \log_{10}(\text{signal}/\text{noise})$) for each grayscale patch									
Zone	Y-S/N	R-S/N	G-S/N	B-S/N	Y-SNR(dB)	R-SNR(dB)	G-SNR(dB)	B-SNR(dB)	
19	56.4	47.18	54.06	50.33	35.03	33.48	34.66	34.04	
20	45.48	38.12	43.86	42.06	33.16	31.62	32.84	32.48	
21	37.4	30.33	36.26	33.55	31.46	29.64	31.19	30.51	
22	32.09	26	30.9	29.54	30.13	28.3	29.8	29.41	
23	24.94	19.94	24.19	23.07	27.94	26	27.67	27.26	
24	17.47	14.47	16.81	16.2	24.85	23.21	24.51	24.19	

去噪影片SNR(Imatest)

以Imatest实际测试结果来说，去噪后相较充满噪音的影片SNR明显提高

S/N (signal/noise) and SNR(dB) ($20 \cdot \log_{10}(\text{signal}/\text{noise})$) for each grayscale patch								
Zone	Y-S/N	R-S/N	G-S/N	B-S/N	Y-SNR(dB)	R-SNR(dB)	G-SNR(dB)	B-SNR(dB)
19	170.55	149.55	163.37	132.82	44.64	43.5	44.26	42.47
20	103.63	101.38	102.36	88.58	40.31	40.12	40.2	38.95
21	89.52	81.2	87.9	60.23	39.04	38.19	38.88	35.6
22	73.11	72.57	73.23	58.97	37.28	37.21	37.29	35.41
23	37.65	33.28	33.83	23.12	31.52	30.44	30.59	27.28
24	24.75	21.68	25.3	24.08	27.87	26.72	28.06	27.63

训练集结果

可以看到：

1. 天空云彩颗粒感改善
2. 墙壁噪点还原较平滑
3. 地砖细节纹理改善



Noisy Frame

Denoised Frame

Original Frame

训练集结果



Noisy Frame



Denoised Frame



Original Frame

测试集结果

可以看到：

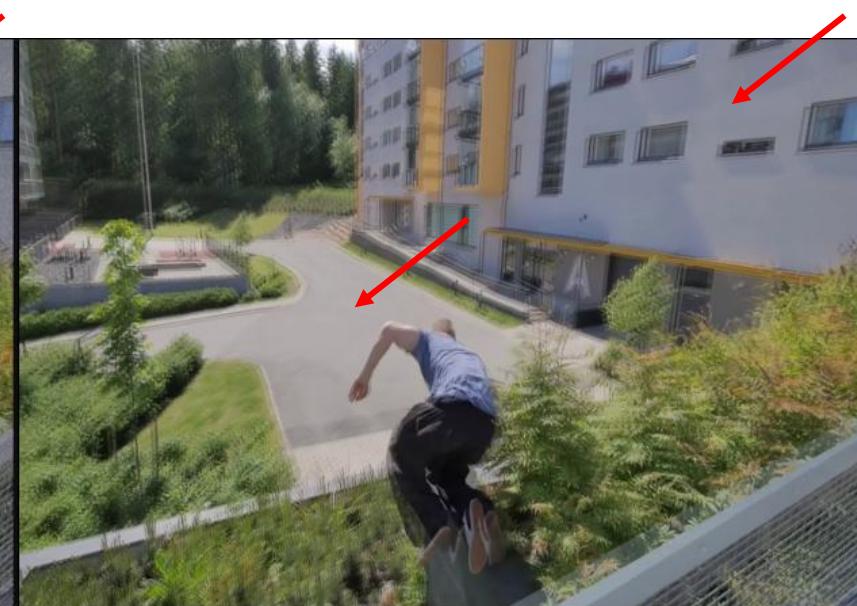
1. 墙壁噪点还原较平滑
2. 地面颗粒感减少很多



Noisy Frame



Denoised Frame



Original Frame

测试集结果



Noisy Frame

Denoised Frame

Original Frame